

Μάθημα: Βαθιά Μάθηση (ΕΠ22στ)

Τίτλος: Σύγχρονες Μέθοδοι Βαθιάς Μάθησης: Συγκριτική Μελέτη σε Δορυφορικά Δεδομένα

Τύπος εργασίας: Ατομική εργασία

Προθεσμία υποβολής: Κυριακή 18 Ιανουαρίου 2026, 23:55.

Τρόπος παράδοσης: Αποκλειστικά μέσω eclass.

Παραδοτέο: Ένα (1) Jupyter Notebook (.ipynb) και README σε αρχείο ZIP.

Βαθμολογία: 100 μονάδες.

ΣΤΟΧΟΣ ΕΡΓΑΣΙΑΣ

Η εργασία αποσκοπεί στην κατανόηση διαφορετικών σύγχρονων παραδειγμάτων μάθησης μέσω της υλοποίησης, εκπαίδευσης και συγκριτικής αξιολόγησης διαφορετικών μεθόδων σε ένα ενιαίο πρόβλημα ταξινόμησης εικόνων. Θα εφαρμόσετε supervised learning, transfer learning, few-shot learning, zero-shot learning, self-supervised learning (SimCLR), και parameter-efficient fine-tuning (LoRA).

Ο στόχος δεν είναι η επίτευξη state-of-the-art επίδοσης, αλλά η κατανόηση των μεθόδων, η διατύπωση ουσιαστικών συμπερασμάτων και η σωστή πειραματική διαδικασία.

Όλα τα πειράματα μπορούν να υλοποιηθούν σε Google Colab Free (GPU T4) ή αντίστοιχο, με κατάλληλη διαχείριση των πόρων όπως τον περιορισμό του αριθμού των epochs και δυνατότητα χρήσης υποσυνόλου δεδομένων για τις πιο απαιτητικές μεθόδους.

ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ

Σε αυτή την εργασία θα χρησιμοποιήσετε το σύνολο δεδομένων EuroSAT στην έκδοση RGB. Το dataset αποτελείται από 10 κατηγορίες χρήσης γης και περιλαμβάνει περίπου 27.000 δορυφορικές εικόνες. Κάθε εικόνα έχει διάσταση 64×64 pixels σε μορφή RGB, ενώ οι κλάσεις είναι ισορροπημένες. Το dataset είναι διαθέσιμο τόσο από το torchvision.datasets.EuroSAT όσο και μέσω της πλατφόρμας HuggingFace.

Για τη μέθοδο SimCLR επιτρέπεται η χρήση υποσυνόλου που περιλαμβάνει 10.000 έως 15.000 εικόνες με σκοπό τη μείωση του χρόνου εκτέλεσης. Σε περίπτωση που επιλέξετε αυτή την προσέγγιση, θα πρέπει να το αναφέρετε ρητά στο αρχείο README της εργασίας σας.

ΔΟΜΗ JUPYTER NOTEBOOK

0: Προετοιμασία και Σύνολο Δεδομένων

1: Baseline και Transfer Learning

2: Few-Shot και Zero-Shot Learning

3: Self-Supervised Learning (SimCLR)

4: Parameter-Efficient Fine-Tuning (LoRA)

5: Συγκριτική Ανάλυση Αποτελεσμάτων και Συμπεράσματα

Κάθε ερώτηση πρέπει να απαντάται σε ξεχωριστό markdown κελί αμέσως μετά τον αντίστοιχο κώδικα.

0 – Προετοιμασία και Σύνολο Δεδομένων (5 μονάδες)

Εργασίες (Tasks):

1. Φόρτωση του EuroSAT και παρουσίαση βασικών πληροφοριών (συνολικό μέγεθος, λίστα κλάσεων, διαστάσεις εικόνων).
2. Preprocessing και κατάλληλες augmentations για δορυφορικές εικόνες.
3. Δημιουργία πέντε splits:
 - Train Full: 70% των δεδομένων
 - Train 10-shot: 10 δείγματα ανά κλάση
 - Train 5-shot: 5 δείγματα ανά κλάση
 - Validation: 15% των δεδομένων
 - Test: 15% των δεδομένων
4. Οπτικοποιήσεις: ενδεικτικά δείγματα ανά κλάση, κατανομή εικόνων ανά κλάση, παραδείγματα εικόνων μετά από augmentations.

Ερωτήσεις:

Q0.1 Περιγράψτε αναλυτικά τα splits που δημιουργήσατε (μέγεθος κάθε split συνολικά και ανά κλάση). Πώς διασφαλίσατε ότι δεν υπάρχει data leakage μεταξύ των συνόλων train, validation και test;

Q0.2 Ποιες augmentations θα χρησιμοποιήσετε και γιατί θεωρούνται κατάλληλες και ρεαλιστικές για δορυφορικές εικόνες;

1 – Baseline και Transfer Learning (20 μονάδες)

Task 1.1 – Baseline CNN από το μηδέν (5 μονάδες)

Υλοποιήστε ένα μικρό Convolutional Neural Network (2–4 convolutional layers) και εκπαιδεύστε το από την αρχή, ώστε να αποτελέσει βασικό σημείο αναφοράς (baseline).

Προτεινόμενες παράμετροι: Optimizer: Adam, learning rate: $1e-3$, batch size: 32–64, epochs: 8–12.

Ερωτήσεις:

Q1.1 Περιγράψτε την αρχιτεκτονική του baseline μοντέλου (αριθμός και τύπος layers, activation functions, pooling).

Q1.2 Παρουσιάστε γραφήματα εκπαίδευσης (training και validation curves για loss ή/και accuracy) και αναφέρετε το τελικό test accuracy.

Q1.3 Αναφέρετε τον συνολικό χρόνο εκπαίδευσης και τον αριθμό παραμέτρων του μοντέλου.

Task 1.2 – Transfer Learning (10 μονάδες)

Transfer learning σε τρία (3) μοντέλα:

- ResNet18 (συνιστάται για ταχύτερη εκτέλεση) ή ResNet50
- EfficientNet-B0
- Vision Transformer (ViT-B/16)

ΣΗΜΑΝΤΙΚΕΣ ΟΔΗΓΙΕΣ:

- Χρησιμοποιήστε ΜΟΝΟ μοντέλα που έχουν προεκπαιδευτεί σε ImageNet ή ImageNet-21k
- ΜΗΝ χρησιμοποιήσετε μοντέλα που έχουν ήδη υποστεί fine-tuning σε EuroSAT, BigEarthNet ή άλλα remote sensing datasets
- Για Vision Transformer: Χρησιμοποιήστε το standard "google/vit-base-patch16-224" (HuggingFace) ή το torchvision ViT-B/16. Το ViT απαιτεί resize των εικόνων σε 224×224 (αντί για 64×64).

Για κάθε μοντέλο εξετάστε δύο στρατηγικές:

1. Full fine-tuning: Εκπαίδευση όλων των παραμέτρων
2. Frozen backbone: Πάγωμα όλων των layers εκτός από το classification head

Ερωτήσεις:

Q1.4 Συμπληρώστε τον παρακάτω πίνακα:

Μοντέλο	Στρατηγική	Test Accuracy (%)	Training Time	Trainable Parameters
Μοντέλο 1	Full FT			
Μοντέλο 1	Frozen			
Μοντέλο 2	Full FT			
Μοντέλο 2	Frozen			
Μοντέλο 3	Full FT			
Μοντέλο 3	Frozen			

Q1.5 Ποιο μοντέλο και ποια στρατηγική (full fine-tuning ή frozen) απέδωσαν καλύτερα και γιατί πιστεύετε ότι συνέβη αυτό;

Q1.6 Πώς επηρέασε το freezing του backbone τον χρόνο εκπαίδευσης και την τελική απόδοση;

Q1.7 Συγκρίνετε ποιοτικά τη συμπεριφορά του Vision Transformer με τα CNN-based μοντέλα στο EuroSAT. Υπάρχουν διαφορές στην απόδοση, το training time, ή τη data efficiency;

Task 1.3 – Transfer Learning σε Few-Shot σενάρια (5 μονάδες)

Επιλέξτε τα δύο configurations (συνδυασμούς μοντέλου και στρατηγικής) με την υψηλότερη test accuracy από το Task 1.2. Εκπαιδεύστε αυτά τα configurations, διατηρώντας την ίδια στρατηγική (full fine-tuning ή frozen), στα few-shot splits:

- Train 10-shot (10 εικόνες ανά κλάση)
- Train 5-shot (5 εικόνες ανά κλάση)

Ερωτήσεις:

Q1.8 Συμπληρώστε τον παρακάτω πίνακα:

Μοντέλο	Full Data (%)	10-shot (%)	5-shot (%)
Best Model 1			
Best Model 2			

Q1.9 Ποιο μοντέλο αποδείχθηκε πιο data-efficient (δηλαδή η απόδοσή του πέφτει λιγότερο όταν μειώνονται τα διαθέσιμα δεδομένα) και γιατί.

Q1.10 Παρουσιάστε confusion matrix για το 5-shot σενάριο και σχολιάστε ποιες κλάσεις συγχέονται περισσότερο.

2 – Few-Shot και Zero-Shot Learning (20 μονάδες)

Task 2.1 – Prototype-based Few-Shot Classifier (12 μονάδες)

Υλοποιήστε έναν ταξινομητή βασισμένο σε prototypes:

1. Χρησιμοποιήστε έναν pretrained encoder (π.χ. ResNet18 με ImageNet weights, frozen χωρίς fine-tuning) για να εξάγετε embeddings από τις εικόνες.
2. Για κάθε κλάση, υπολογίστε το prototype της ως τον μέσο όρο (mean) των embeddings των samples της κλάσης.
3. Για κάθε test sample, υπολογίστε την απόστασή του από όλα τα prototypes και αποδώστε την κλάση του πλησιέστερου prototype.

Χρησιμοποιήστε τα ίδια 5-shot και 10-shot splits από το Task 1.3 ως support sets για τον υπολογισμό των prototypes. Αξιολογήστε στο ίδιο test set για fair comparison.

Ερωτήσεις:

Q2.1 Δοκιμάστε δύο μετρικές απόστασης (Euclidean και Cosine) και σχολιάστε ποια αποδίδει καλύτερα.

Q2.2 Συγκρίνετε την επίδοση του prototype-based classifier με το καλύτερο configuration του transfer learning από το Task 1.3 στα few-shot σενάρια:

Support Set	Prototype Classifier (%)	Transfer Learning (%)
5-shot		
10-shot		

Q2.3 Ποια προσέγγιση (prototype-based vs transfer learning) αποδίδει καλύτερα στο few-shot regime και γιατί;

Q2.4 Ποια είναι τα κύρια πλεονεκτήματα και μειονεκτήματα του prototype-based classifier σε σχέση με το supervised fine-tuning;

Task 2.2 – Zero-Shot Learning με CLIP (8 μονάδες)

Χρησιμοποιήστε το προεκπαιδευμένο μοντέλο CLIP (ViT-B/32) σε zero-shot mode. Δεν θα κάνετε καμία εκπαίδευση ή fine-tuning στο EuroSAT, το CLIP χρησιμοποιείται ως έχει για ταξινόμηση μέσω text prompts. Αξιολογήστε το CLIP στο ίδιο test set που χρησιμοποιήθηκε στα Μέρη 1 και 2.1 για fair comparison.

Τεχνικές απαιτήσεις: Το CLIP απαιτεί συγκεκριμένο preprocessing: resize εικόνων σε 224×224 και normalization. Χρησιμοποιήστε το CLIPProcessor (HuggingFace) ή το clip.preprocess (OpenAI).

Βήματα υλοποίησης:

1. Basic prompt: Ορίστε ένα απλό prompt της μορφής "a satellite image of {class_name}"
2. Domain-specific prompts: Δημιουργήστε 2–3 εξειδικευμένα prompts, π.χ. "an aerial view of {class_name} terrain", "a satellite photograph showing {class_name} land use", "top-down view of {class_name} area"
3. Prompt ensembling: Υπολογίστε text embeddings για όλα τα prompts και συνδυάστε τα (π.χ. με μέσο όρο) για να δημιουργήσετε ένα ensemble prompt.

Ερωτήσεις:

Q2.5 Συγκρίνετε την επίδοση με τα διαφορετικά prompts:

Prompt Strategy	Test Accuracy (%)
Basic prompt	
Domain prompt 1	
Domain prompt 2	
Domain prompt 3 (αν υπάρχει)	
Ensemble	

Q2.6 Συγκρίνετε την επίδοση του CLIP zero-shot με την επίδοση του καλύτερου configuration από το 5-shot transfer learning του Task 1.3. Τι παρατηρείτε;

Q2.7 Ποιες κλάσεις αναγνωρίζει καλά το CLIP και ποιες όχι; Προσπαθήστε να ερμηνεύσετε τα αποτελέσματα (π.χ. βάσει των ονομάτων των κλάσεων, της οπτικής τους ομοιότητας, κτλ.).

Q2.8 Αν είχατε μηδέν labeled δεδομένα, θα επιλέγατε CLIP zero-shot ή self-supervised pretraining με λίγα labels στη συνέχεια; Τεκμηριώστε την απάντησή σας.

3 – Self-Supervised Learning (SimCLR) (20 μονάδες)

Task 3.1 – Υλοποίηση και Αξιολόγηση SimCLR (20 μονάδες)

Υλοποιήστε το SimCLR framework για self-supervised pretraining στο EuroSAT (ή σε υποσύνολό του).

Αρχιτεκτονική: Encoder: ResNet18 ή ResNet34, Projection head: Μικρό MLP με δύο fully-connected layers

Augmentations (για δημιουργία θετικών ζευγών): Random resized crop, Horizontal flip, Color jitter, Gaussian blur

Loss: NT-Xent (Normalized Temperature-scaled Cross Entropy) με temperature $\tau = 0.5$

Εκπαίδευση:

- Pretraining για 30–50 epochs
- Batch size: 128–256 (όσο επιτρέπει η διαθέσιμη μνήμη GPU)
- Σημείωση για memory: Αν αντιμετωπίσετε Out Of Memory errors, μειώστε το batch size σε 64 ή χρησιμοποιήστε μικρότερο υποσύνολο δεδομένων
- Αν χρησιμοποιήσετε υποσύνολο, αναφέρετε το μέγεθός του στο README

Αξιολόγηση του SimCLR:

1. **Linear evaluation:** Freeze τον encoder, εκπαιδεύστε έναν linear classifier πάνω στα embeddings χρησιμοποιώντας το full train set
2. **Fine-tuning με full data:** Unfreeze τον encoder και κάντε fine-tuning στο full train set
3. **Fine-tuning με few-shot data:** Unfreeze τον encoder και κάντε fine-tuning στα 10-shot και 5-shot splits από το Task 1.3

Σημείωση: Το linear evaluation εκτελείται μόνο με full data. Τα few-shot scenarios αφορούν αποκλειστικά fine-tuning του encoder.

Ερωτήσεις:

Q3.1 Εξηγήστε τον ρόλο των augmentations στο contrastive learning. Γιατί είναι κρίσιμες για την ποιότητα των representations;

Q3.2 Συμπληρώστε τον παρακάτω πίνακα που συγκρίνει το SimCLR με το ImageNet transfer learning (best configuration από Task 1.3):

Method	Full Data (%)	10-shot (%)	5-shot (%)
SimCLR (linear eval)		N/A	N/A
SimCLR (fine-tuned)			
ImageNet pretrained (best config)			

Q3.3 Είναι το self-supervised pretraining στο EuroSAT καλύτερο από το ImageNet transfer learning; Σε ποιες περιπτώσεις και γιατί;

Q3.4 Παρουσιάστε t-SNE ή UMAP visualization των embeddings του pretrained SimCLR encoder για το test set. Ποιες κλάσεις είναι κοντά στο embedding space και πώς αυτό σχετίζεται με τα λάθη που κάνει ο linear classifier; **Είναι αυτή η συμπεριφορά αναμενόμενη;**

Q3.5 (Προαιρετικό) Ablation study: Δοκιμάστε διαφορετικές τιμές του temperature (π.χ. $\tau = 0.1, 0.5, 1.0$) και σχολιάστε την επίδραση.

Q3.6 Σε ποιο data regime (full data / 10-shot / 5-shot) το SimCLR προσφέρει τα μεγαλύτερα οφέλη έναντι του ImageNet transfer learning;

Q3.7 Αν διαθέτατε πολύ μεγάλο αριθμό unlabeled δορυφορικών εικόνων, αλλά ελάχιστα labeled (π.χ. 5–10 εικόνες ανά κλάση), ποια στρατηγική θα επιλέγατε και γιατί;

4 – Parameter-Efficient Fine-Tuning με LoRA (10 μονάδες)

Task 4.1 – LoRA σε Vision Transformer

Χρησιμοποιήστε τη βιβλιοθήκη PEFT (HuggingFace) για να εφαρμόσετε LoRA στο ViT-B/16 που υλοποιήσατε στο Task 1.2.

Ρυθμίσεις:

- LoRA rank: $r = 8$
- Εφαρμόστε LoRA στα attention modules (query και value projections)
- Freeze όλες τις υπόλοιπες παραμέτρους
- Εκπαίδευση: full train set (70%), 5–10 epochs

Ερωτήσεις:

Q4.1 Συγκρίνετε full fine-tuning και LoRA συμπληρώνοντας τον πίνακα (χρησιμοποιήστε τα αποτελέσματα του ViT full fine-tuning από το Task 1.2):

Method	Trainable Params (M)	Trainable Params (%)	Test Accuracy (%)	Training Time
Full fine-tuning		100%		
LoRA (r=8)				

Q4.2 Με βάση τα αποτελέσματα, πόσο μικρή είναι η πτώση στην ακρίβεια του LoRA σε σχέση με το full fine-tuning; Δικαιολογείται αυτή η πτώση (αν υπάρχει) από τα οφέλη σε trainable parameters και training time;

Q4.3 Περιγράψτε δύο συγκεκριμένα σενάρια όπου η χρήση LoRA προσφέρει σημαντικά πλεονεκτήματα έναντι του full fine-tuning: (α) σενάριο με πολλαπλά downstream tasks, και (β) σενάριο με περιορισμούς στην υπολογιστική ισχύ ή μνήμη.

5 – Συγκριτική Ανάλυση και Συμπεράσματα (10 μονάδες)

Task 5.1 – Ενιαίο Benchmark

Συγκεντρώστε τα καλύτερα αποτελέσματα (test accuracy) από κάθε μέθοδο σε έναν ενιαίο συγκριτικό πίνακα.

Οδηγίες για τον πίνακα:

- Για τη στήλη "Training Cost": Αναφέρετε τον χρόνο εκπαίδευσης σε λεπτά
- N/A σημαίνει ότι η μέθοδος δεν εφαρμόζεται σε αυτό το scenario

Method	Full Data (%)	10-shot (%)	5-shot (%)	Zero-shot (%)	Training Cost
Baseline CNN		N/A	N/A	N/A	
Best Transfer Learning (full FT)				N/A	
Prototype Classifier	N/A			N/A	
CLIP Zero-Shot	N/A	N/A	N/A		
SimCLR (linear eval)		N/A	N/A	N/A	
SimCLR (fine-tuned)				N/A	
LoRA (ViT)		N/A	N/A	N/A	

Ερωτήσεις:

Q5.1 Συμπληρώστε τον παραπάνω πίνακα με τα αποτελέσματά σας.

Q5.2 Δημιουργήστε ένα οπτικό διάγραμμα (grouped bar plot) που απεικονίζει το test accuracy των μεθόδων στα τέσσερα data regimes (Full Data, 10-shot, 5-shot, Zero-shot). Ποια μέθοδος υπερτερεί σε κάθε regime;

Task 5.2 – Insights και Συμπεράσματα

Q5.3 Ποια μέθοδος είναι η καταλληλότερη για κάθε ένα από τα παρακάτω σενάρια; Τεκμηριώστε την απάντησή σας με βάση τα αποτελέσματά σας.

- Πολλά labeled δεδομένα (thousands of samples)
- 10 labeled παραδείγματα ανά κλάση
- 5 labeled παραδείγματα ανά κλάση
- Μηδέν labeled δεδομένα (zero-shot)

Q5.4 Κατατάξτε τις μεθόδους ως προς το υπολογιστικό κόστος εκπαίδευσης (από την πιο ελαφριά στην πιο βαριά). Εξηγήστε ποιοι παράγοντες (αρχιτεκτονική, αριθμός epochs, pretraining, κτλ.) επηρεάζουν το κόστος κάθε μεθόδου.

Q5.5 Πότε προτιμάται το ImageNet transfer learning και πότε το self-supervised pretraining στο ίδιο το EuroSAT dataset; Αναφέρετε συγκεκριμένα πλεονεκτήματα και μειονεκτήματα κάθε προσέγγισης.

Q5.6 Πότε αξίζει η χρήση LoRA και πότε θα προτιμούσατε full fine-tuning; Σε ποια σενάρια το trade-off μεταξύ accuracy και efficiency κλίνει υπέρ του LoRA;

Q5.7 Ποια επιπλέον πειράματα ή επεκτάσεις (future work) θα θέλατε να υλοποιήσετε αν είχατε περισσότερο χρόνο ή υπολογιστικούς πόρους;

ΠΟΛΙΤΙΚΗ ΧΡΗΣΗΣ ΕΡΓΑΛΕΙΩΝ ΤΕΧΝΗΤΗΣ ΝΟΗΜΟΣΥΝΗΣ

Επιτρέπεται η χρήση εργαλείων AI (ChatGPT, Claude, Copilot κ.λπ.) για:

- Debugging κώδικα
- Βελτιστοποίηση κώδικα
- Ερωτήσεις σύνταξης (syntax)
- Σύνοψη τεκμηρίωσης (docstrings)
- Διευκρίνιση εννοιών (π.χ. τι είναι LoRA, πώς λειτουργεί το SimCLR)

Απαγορεύεται:

- Αντιγραφή ολόκληρων υλοποιήσεων χωρίς κατανόηση
- Αυτόματη δημιουργία των απαντήσεων στις θεωρητικές ερωτήσεις
- Plagiarism από online πηγές ή εργαλεία AI χωρίς σαφή αναφορά

Υποχρεωτική Δήλωση Χρήσης AI:

Στο τέλος του notebook, προσθέστε ένα markdown κελί με τίτλο "Δήλωση Χρήσης AI Tools" και περιγράψτε:

- Ποια εργαλεία χρησιμοποιήσατε
- Για ποιους σκοπούς
- Δήλωση ότι έχετε κατανοήσει και επαληθεύσει τον κώδικα και τα πειραματικά αποτελέσματα

ΒΑΘΜΟΛΟΓΙΑ

Σύνολο: 100 μονάδες

Αναλυτική κατανομή:

- 0: 5 μονάδες
- 1: 20 μονάδες
- 2: 20 μονάδες
- 3: 20 μονάδες
- 4: 10 μονάδες
- 5: 10 μονάδες
- Ποιότητα κώδικα και παρουσίασης αποτελεσμάτων : 15 μονάδες

ΟΔΗΓΙΕΣ ΥΠΟΒΟΛΗΣ

Υποβάλλετε ένα αρχείο ZIP με όνομα: **AM_Επώνυμο_DeepLearning.zip**

Το ZIP πρέπει να περιέχει:

1. **Jupyter Notebook:** AM_Επώνυμο_DeepLearning.ipynb
2. **Αρχείο README.txt** με τα εξής:
 - Ονοματεπώνυμο
 - Αριθμός Μητρώου (AM)
 - Αν χρησιμοποιήθηκε υποσύνολο δεδομένων και ποιου μεγέθους
 - Λίστα βασικών dependencies (π.χ. PyTorch, torchvision, transformers, peft, scikit-learn, matplotlib, κτλ.)
 - Εκτιμώμενος συνολικός χρόνος εκτέλεσης του notebook (σε λεπτά)
 - Περιγραφή hardware που χρησιμοποιήθηκε (π.χ. Google Colab Free GPU T4)

Σημείωση: Μην συμπεριλάβετε τα δεδομένα (EuroSAT) ή μεγάλα αρχεία checkpoints στο ZIP. Αρκεί να παρέχετε τον κώδικα που κατεβάζει/φορτώνει τα δεδομένα.

ΣΕ ΠΕΡΙΠΤΩΣΗ ΤΕΧΝΙΚΩΝ ΠΡΟΒΛΗΜΑΤΩΝ

Αν αντιμετωπίσετε σοβαρό τεχνικό πρόβλημα που δεν μπορείτε να λύσετε:

1. **Τεκμηριώστε το πρόβλημα** στο notebook:
 - Τι ακριβώς προσπαθήσατε να κάνετε
 - Ποια error messages παρατηρήσατε
 - Ποια troubleshooting βήματα ακολουθήσατε
2. **Παρουσιάστε μερικά αποτελέσματα:**
 - Αν το SimCLR pretraining δεν ολοκληρώθηκε, παρουσιάστε τα αποτελέσματα των πρώτων 20–30 epochs
 - Αν το ViT-B/16 προκαλεί Out-of-Memory errors, μειώστε το batch size (π.χ. σε 8 ή 4) ή/και χρησιμοποιήστε mixed-precision training (torch.cuda.amp). Σε ακραία περίπτωση μπορείτε να εκπαιδεύσετε λιγότερα epochs.
 - Αν κάποιο πείραμα απέτυχε εντελώς, εξηγήστε τι δοκιμάσατε και τι πιστεύετε ότι πήγε στραβά.